

FIAP — Prompt Engineering & AI

Checkpoint 02 — Prompt Toolkit

Integrantes:

Erik Medveder Nikoluk 567996

Ana Flávia Couto Chaves 566603

Nicolly Giroto rm 568204

Henry de Oliveira Vasconcellos 566836

Professor: Jorge Luiz Gomes

1. Introdução

O projeto foi desenvolvido com o objetivo de comparar diferentes técnicas de prompting utilizando modelos LLM executados localmente via Ollama. O domínio escolhido foi e-commerce, focando em classificação de sentimento, extração de informações e geração de emails automáticos.

2. Arquitetura do Sistema

O sistema foi organizado em arquitetura modular utilizando Python.

- llm_client.py → comunicação com Ollama
- prompt_builder.py → construção dos prompts
- techniques.py → implementação das técnicas
 - evaluator.py → métricas e avaliação
- report.py → geração de tabelas e gráficos

3. Fluxo do Sistema

inputs.json → prompt_builder.py → techniques.py → llm_client.py → evaluator.py → report.py → output/

4. Stack Tecnológica

Tecnologia	Uso
Python 3.14	Linguagem principal
Ollama	Execução local do LLM
llama3	Modelo de IA

pandas	Manipulação de tabelas
matplotlib	Geração de gráficos

5. Técnicas Implementadas

Zero-Shot/

Executa a tarefa sem exemplos prévios.

Few-Shot

Utiliza exemplos para orientar o modelo.

Chain-of-Thought

Força o modelo a raciocinar passo a passo.

Role Prompting

Utiliza personas especializadas através de system prompts.

6. Resultados Obtidos

As técnicas apresentaram tempos diferentes de execução dependendo da complexidade da tarefa. As tarefas de geração de email apresentaram maior tempo médio devido à quantidade de tokens gerados.

7. Guia de Bolso

Técnica	Melhor uso
Zero-Shot	Tarefas simples
Few-Shot	Padrões específicos
CoT	Raciocínio complexo
Role Prompting	Tarefas especializadas

8. Conclusão

O projeto demonstrou que diferentes técnicas de prompting podem impactar significativamente o desempenho e custo computacional dos modelos LLM. Role Prompting apresentou respostas mais consistentes em tarefas complexas, enquanto Zero-Shot teve menor custo computacional.